

Desafio Individual - Detecção de Fraudes em Transações Financeiras com Machine Learning

Mirella Fontinelle

Centro de Informática (CIn)

Universidade Federal de Pernambuco (UFPE)

Recife, Brasil

mlfm@cin.ufpe.br

Abstract—Este trabalho apresenta o desenvolvimento de uma solução para detecção de fraudes em transações financeiras como parte do Desafio Individual do processo seletivo da Liga Acadêmica de Inteligência Artificial da Universidade Federal de Pernambuco. O dataset é caracterizado por forte desbalanceamento de classes — apenas 0,17% de transações fraudulentas — e por 28 variáveis anonimizadas obtidas via Análise de Componentes Principais (PCA). A análise exploratória confirmou ausência de valores faltantes, ortogonalidade estrutural entre as componentes V1–V28 e separabilidade espacial significativa entre as classes, concentrada nas variáveis V17, V14, V12, V10 e V3. Três modelos foram comparados sob validação cruzada estratificada com 5 folds: Regressão Logística ($AUC = 0,9805 \pm 0,0114$), Random Forest ($AUC = 0,9658 \pm 0,0149$) e XGBoost com ajuste fino ($AUC = 0,9872 \pm 0,0078$). O modelo final integra técnicas de interpretabilidade via SHAP, com explicações globais e locais consistentes com os padrões identificados desde a etapa exploratória, mitigando o tratamento da solução como caixa-preta em um domínio de alto impacto financeiro.

Index Terms—Aprendizado de Máquina, Detecção de Fraude, XGBoost, Interpretabilidade.

I. INTRODUÇÃO

A detecção de fraudes em sistemas de pagamentos eletrônicos é um problema clássico e de alta relevância prática em Ciência de Dados. A raridade dos eventos de fraude impõe barreiras severas à aprendizagem de máquina convencional: em alguns casos é possível atingir acurácia superior a 99% ao classificar todas as transações como legítimas, mesmo sem qualquer utilidade operacional real [1]. Nesse contexto, maximizar a acurácia global não deve ser o objetivo central, mas sim otimizar a capacidade de ordenação de risco entre os diferentes limiares de decisão — motivando a adoção da ROC-AUC como métrica principal de avaliação.

O dataset utilizado é composto por transações financeiras, cujas variáveis V1–V28 foram obtidas por transformação PCA. As únicas variáveis originais mantidas são *Time*, que registra o instante da transação em segundos ao longo de aproximadamente dois dias consecutivos, e *Amount*, que representa o valor monetário da operação. Das 227.845 transações disponíveis no conjunto de treino, apenas 394 (0,17%) correspondem à classe fraudulenta, configurando um cenário de desbalanceamento extremo.

Este trabalho está organizado em torno de três pilares metodológicos: (i) análise exploratória dos dados, com foco na integridade do dataset, distribuição das variáveis

e identificação de componentes com maior poder discriminatório; (ii) construção de um pipeline de modelagem robusto, considerando a natureza não linear da separação entre classes observada nas projeções espaciais; e (iii) aplicação de técnicas de interpretabilidade para análise dos fatores que influenciam as decisões do modelo, com ênfase na justificativa das escolhas técnicas realizadas.

Como ilustrado na Figura 1, transações fraudulentas ocupam regiões específicas do espaço PCA, deslocadas para valores negativos nas componentes de maior poder discriminatório — padrão que motivou a adoção de modelos baseados em boosting como abordagem principal.




Fig. 1. Separação espacial entre classes no espaço PCA (V3 vs V14). Transações fraudulentas ocupam região distinta, deslocada para valores negativos em ambas as componentes.

II. METODOLOGIA

O pipeline de desenvolvimento foi estruturado em três etapas principais: pré-processamento dos dados, comparação entre modelos via validação cruzada e refinamento da solução final.

A. Pré-processamento

A variável *id* foi removida por representar um identificador único sem conteúdo preditivo. A ausência de valores faltantes foi confirmada, dispensando imputação. As variáveis V1–V28, por serem componentes principais já padronizadas, não requerem escalonamento adicional — fato corroborado

pela ausência de correlações lineares relevantes entre elas, confirmada empiricamente pela matriz de correlação.

A variável `Amount` recebeu transformação logarítmica (`log1p`) para reduzir a assimetria da distribuição e a influência de valores extremos. A variável `Time` foi mantida sem transformação: a análise exploratória identificou variação na taxa de fraude ao longo dos decis temporais (diferença de até 3,5 vezes entre o intervalo de menor e maior incidência), indicando potencial preditivo relevante. A utilização de `ColumnTransformer` garante que as transformações sejam aplicadas de forma controlada e reproduzível, evitando vazamento de informação em validação cruzada.

B. Estratégia de Balanceamento

Dado o forte desbalanceamento (0,17% de fraudes), optou-se pelo uso de `class_weight='balanced'` nos modelos lineares e por `scale_pos_weight` no XGBoost. O valor foi calculado como:

$$\text{scale_pos_weight} = \frac{|N_{\text{legítimas}}|}{|N_{\text{fraudes}}|} \approx 577,3 \quad (1)$$

Essa formulação ajusta o gradiente durante o treinamento de forma que cada erro na classe minoritária receba peso proporcional ao desequilíbrio, mantendo a função de perda efetivamente balanceada sem modificar a distribuição dos dados.

Técnicas de oversampling sintético como SMOTE foram descartadas: quando aplicadas antes da validação cruzada, introduzem risco de *data leakage*, pois amostras sintéticas geradas a partir do conjunto de treino podem ter vizinhos no conjunto de validação, inflando artificialmente as métricas [4].

C. Modelos Avaliados e Protocolo de Validação

Todos os modelos foram avaliados sob o mesmo protocolo de *StratifiedKFold* com 5 folds e `shuffle=True`. A escolha do *StratifiedKFold* em detrimento do *KFold* convencional é crítica neste contexto: com apenas 0,17% de fraudes, uma divisão aleatória poderia gerar folds com zero ou pouquíssimas instâncias positivas, tornando a ROC-AUC indefinida e a estimativa de desempenho instável. A estratificação garante que a proporção entre classes seja preservada em cada fold, assegurando estimativas confiáveis e comparáveis entre modelos.

Regressão Logística foi utilizada como baseline interpretável, implementada via `Pipeline` com transformação logarítmica no `Amount`. A escolha justifica-se pela natureza PCA do espaço de features: componentes principais são direções de máxima variância no espaço original, e separação linear nesse espaço é esperada quando as classes diferem estruturalmente na covariância dos dados.

Random Forest com 300 estimadores e `class_weight='balanced'` foi avaliado como representante de modelos ensemble baseados em bagging, permitindo capturar interações não-lineares sem especificação explícita.

XGBoost foi o modelo principal, treinado em dois estágios. Um baseline com hiperparâmetros conservadores estabeleceu o patamar de desempenho. Em seguida, o modelo foi otimizado com `n_estimators=5000`, `max_depth=6`, `learning_rate=0.02`, `subsample=0.8`, `colsample_bytree=0.8` e `min_child_weight=7`, com *early stopping* configurado para 200 rodadas sem melhoria. A taxa de aprendizado reduzida combinada ao número elevado de estimadores com parada antecipada permite correções incrementais mais finas, enquanto o *early stopping* impede ajuste de ruído após o ponto ótimo. O número final de estimadores foi determinado pela média das melhores iterações entre os 5 folds (≈ 559 árvores), e o modelo foi retreinado sobre o conjunto completo.

III. RESULTADOS E DISCUSSÃO

A. Análise de Erros

A Figura 2 apresenta a matriz de confusão do modelo final avaliada em um fold de validação com threshold de decisão 0,5.




Fig. 2. Matriz de confusão do XGBoost com threshold de decisão 0,5.

O modelo detectou 65 das 78 transações fraudulentas no fold de validação, resultando em recall de 0,833 e precisão de 0,756. Os 13 falsos negativos representam o erro de maior impacto operacional, pois correspondem a fraudes não interceptadas. Os 21 falsos positivos, embora gerem fricção desnecessária ao bloquear transações legítimas, representam apenas 0,046% das transações legítimas do fold — impacto operacional reduzido. O threshold padrão de 0,5 pode ser ajustado conforme o custo relativo de cada tipo de erro no contexto operacional: reduzir o threshold aumenta o recall à custa de mais falsos positivos, enquanto elevá-lo prioriza precisão.

B. Comparação entre Modelos

A Tabela I sumariza o desempenho dos modelos avaliados sob validação cruzada estratificada com 5 folds.

A Regressão Logística superou o Random Forest (0,9805 vs 0,9658), confirmando que a estrutura discriminativa do problema é predominantemente linear no espaço PCA. O Random Forest apresentou ainda maior variabilidade entre

TABLE I
COMPARAÇÃO DE DESEMPENHO — ROC-AUC (CV 5-FOLD)

Modelo	AUC Média	Desvio Padrão
Regressão Logística	0,9805	0,0114
Random Forest	0,9658	0,0149
XGBoost (baseline)	0,9829	0,0100
XGBoost (tuned)	0,9872	0,0078

folds (desvio de 0,0149), sugerindo menor estabilidade em comparação ao modelo linear.

O XGBoost tuned atingiu AUC média de 0,9872 com desvio padrão de apenas 0,0078 — o menor entre todos os modelos — indicando que o ajuste fino não apenas melhorou o desempenho médio, mas também aumentou a estabilidade da solução. O ganho absoluto de 0,0067 pontos de AUC em relação à Regressão Logística, embora numericamente modesto, é consistente entre folds, evidenciando captura de padrões não-lineares residuais sem sobreajuste.

C. Análise da Curva Precision-Recall

A curva Precision-Recall foi avaliada sobre a Regressão Logística como referência de baseline, permitindo contextualizar o ganho obtido pelo modelo final.

A curva Precision-Recall da Regressão Logística evidenciou desempenho robusto em regime de forte desbalanceamento, mantendo precisão próxima a 85% até aproximadamente 75% de recall. A degradação de precisão em níveis elevados de recall é esperada: ampliar a cobertura implica relaxamento do limiar de decisão e aumento de falsos positivos. O comportamento da curva sugere que o modelo produz ranking bem ordenado das transações por risco, permitindo ajuste estratégico do threshold conforme restrições operacionais.

IV. INTERPRETABILIDADE (XAI)

Para evitar que a solução fosse tratada como caixa-preta, aplicou-se a técnica SHAP (*SHapley Additive exPlanations*) [2], que atribui a cada feature uma contribuição marginal para a predição. Dois instrumentos complementares foram utilizados: o Summary Plot, que descreve o comportamento global do modelo, e o Waterfall Plot, que detalha a mecânica preditiva em nível de instância individual.

A. Comportamento Global — Summary Plot

Como ilustrado na Figura 3, as componentes V14, V4, V12 e V10 são os atributos de maior impacto preditivo, com dispersão de valores SHAP significativamente superior às demais variáveis. Observa-se correlação direcional clara: valores baixos de V14 (representados em azul) geram contribuições SHAP fortemente negativas, empurrando o modelo em direção à classe positiva (fraude). V4 apresenta comportamento inverso, com valores elevados associados ao aumento do risco.

Notavelmente, as variáveis originais Amount e Time aparecem no plot com impacto reduzido mas não nulo, confirmando que, embora sua contribuição isolada seja limitada — como identificado na EDA —, elas capturam informação




Fig. 3. SHAP Summary Plot: importância global das features e direção de impacto no modelo final.

residual não completamente representada nas componentes PCA.

Esse padrão converge com os coeficientes da Regressão Logística, que já havia mapeado V14 com peso $-1,21$ e V4 com peso $+0,87$. A consistência entre o modelo linear baseline e os valores SHAP do ensemble consolida a robustez da fronteira de decisão: o XGBoost está apoiado nos mesmos padrões estruturais identificados desde a etapa exploratória, e não em artefatos do conjunto de treino.

B. Comportamento Local — Waterfall Plot

O Waterfall Plot da Figura 4 ilustra a mecânica preditiva em nível individual. A saída do modelo saltou do valor base $E[f(X)] = 1,725$ para log-odds final $f(x) = 8,006$, equivalente a uma probabilidade predita superior a 99%.

As principais contribuições foram: V14 com $+3,29$, V4 com $+1,24$ e V10 com $+1,16$. Variáveis como V8 e V26 exerceram impacto negativo parcial, demonstrando que a decisão final resulta da soma balanceada de forças contribuintes e não de uma única variável dominante. Essa decomposição aditiva torna a decisão auditável e rastreável, requisito fundamental em detecção de fraude, onde a explicabilidade é tão importante quanto o desempenho preditivo [3].

V. LIMITAÇÕES E TRABALHOS FUTUROS

A principal limitação da solução desenvolvida diz respeito à janela temporal restrita do dataset: as transações abrangem aproximadamente dois dias consecutivos, o que impede a




Fig. 4. SHAP Waterfall Plot de transação classificada corretamente como fraude, detalhando a contribuição individual de cada feature.

avaliação da capacidade de generalização do modelo para padrões de fraude em períodos distintos ou sazonais. Modelos treinados em janelas temporais curtas podem não capturar deriva de conceito (*concept drift*), fenômeno comum em sistemas de pagamento onde o comportamento fraudulento evolui continuamente em resposta às medidas de detecção adotadas.

Uma segunda limitação decorre da natureza anonimizada das variáveis V1–V28: a ausência de semântica original impede a validação do significado financeiro das componentes identificadas como mais relevantes pelo SHAP, limitando a interpretabilidade do modelo no contexto de negócio.

Por fim, a estratégia de balanceamento adotada — penalização assimétrica via `scale_pos_weight` — otimiza globalmente a ROC-AUC, mas não permite controle direto sobre o trade-off entre precisão e recall em limiares específicos de decisão, o que pode ser relevante em cenários operacionais onde o custo de falsos positivos e falsos negativos é assimétrico e conhecido.

Como trabalhos futuros, destacam-se: (i) avaliação de modelos em esquema de validação temporal (*walk-forward validation*), preservando a ordem cronológica das transações para simular condições reais de implantação; (ii) aplicação de técnicas de detecção de *concept drift* para monitoramento contínuo do desempenho em produção; e (iii) otimização do limiar de decisão com base em métricas de negócio explícitas, como o custo esperado por transação fraudulenta não detectada.

VI. CONCLUSÃO

Este trabalho apresentou uma solução para detecção de fraudes em transações financeiras sob forte desbalanceamento de classes, desenvolvida como parte do Desafio Individual do processo seletivo da Ligia – UFPE. A análise exploratória revelou que a separabilidade entre classes é estruturalmente concentrada no espaço PCA, com as componentes V14, V12, V10 e V4 apresentando os maiores deslocamentos médios entre transações legítimas e fraudulentas.

A comparação entre três modelos de complexidade crescente evidenciou que a Regressão Logística superou o Random Forest, confirmando a natureza predominantemente linear da fronteira de decisão no espaço transformado. O XGBoost com validação cruzada estratificada e *early stopping* obteve o melhor desempenho, alcançando ROC-AUC de 0,9872 em validação.

Optou-se por um modelo com baixa variância entre folds e evidências consistentes de generalização, priorizando robustez e documentação metodológica rigorosa em detrimento de otimizações pontuais de hiperparâmetros que não se sustentassem sob validação cruzada.

A análise SHAP demonstrou que as decisões do modelo são rastreáveis e consistentes com os padrões identificados desde a etapa exploratória: as mesmas componentes apontadas pela Regressão Logística como mais discriminativas emergiram como as de maior impacto nos valores SHAP do ensemble, consolidando a robustez da solução. A convergência entre interpretabilidade linear e não-linear constitui evidência de que o modelo aprendeu estrutura real dos dados, e não artefatos do treinamento.

REFERENCES

- [1] A. Dal Pozzolo, O. Caelen, R. A. Johnson e G. Bontempi, “Calibrating Probability with Undersampling for Unbalanced Classification,” *2015 IEEE Symposium Series on Computational Intelligence (SSCI)*, Cape Town, África do Sul, 2015.
- [2] S. M. Lundberg e S. Lee, “A Unified Approach to Interpreting Model Predictions,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [3] F. Doshi-Velez e B. Kim, “Towards a Rigorous Science of Interpretable Machine Learning,” *arXiv preprint arXiv:1702.08608*, 2017.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall e W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.